

微服务架构下分布式定向日志采集组件的设计与实现

石洪雷*, 赵涓涓

太原理工大学, 山西太原, 030024

摘要

针对微服务分布式系统中日志分散、格式异构与海量数据导致的节点资源消耗高、网络带宽占用大及集中存储压力大等问题, 本文提出一种分布式定向日志采集框架与原型组件。该框架由网关预筛选、节点定向采集和中心二次过滤三层组成: 日志中心基于网关流量日志动态生成关注清单, 并驱动各节点按清单定向采集应用日志; 节点侧采用固定缓存块算法与压力感知指数退避机制; 通过定向策略三次转换算法贯通三层策略语义。本文基于 Go 语言与 Grafana Loki 完成原型实现, 在 WSL/Docker 八节点集群上开展对比实验 (180s、并发 50、每模式重复 3 次), 并补充十六/三十二节点规模复核、策略仿真消融、基于真实分布的多进程模拟与算法微基准测试。实验结果表明, 定向采集将 Loki 入库量控制在 72 条 (同架构全量基线 4388 ± 1 条, 相对降幅 98.4%, 降幅含定向过滤与发射频率差异的联合效果; 多进程同频模拟表明策略过滤独立降幅为 67.8%); 清空统计后的规模复核中, 十六节点网关流量日志增量为 6703.33 ± 91.78 条、Loki 入库为 48.0 ± 5.2 条, 三十二节点网关流量日志增量为 6692.67 ± 121.88 条、Loki 入库稳定为 99.0 ± 0.0 条; Agent 平均 CPU 与内存相对降低 37.5% 与 2.0%。端到端链路 (Nginx 共享内存 $\rightarrow$ Agent gRPC $\rightarrow$ Redis $\rightarrow$ 关注清单生成) 已实测打通。

关键词: 微服务; 分布式日志采集; 定向过滤; 动态策略; 指数退避; Loki

中图法分类号: TP393 **文献标识码:** A

建议引用格式: 石洪雷, 赵涓涓. 微服务架构下分布式定向日志采集组件的设计与实现 [J]. 软件学报投稿稿, 2026.

Design and Implementation of a Distributed Directed Log Collection Component in Microservice Architecture

Abstract: In microservice systems, dispersed and heterogeneous logs impose high overhead on node resources, network bandwidth, and centralized storage. This paper presents

*通讯作者, E-mail: shihonglei0042@link.tyut.edu.cn

a distributed directed log collection framework and prototype component. The framework consists of three layers: gateway pre-filtering, node-side directed collection, and center-side secondary filtering. The log center dynamically generates attention lists from gateway traffic logs to drive directed application-log collection at each node. Node-side fixed-size cache blocks and pressure-aware exponential backoff ensure reliable transmission under resource constraints, while a triple strategy transformation preserves policy semantics across the three layers. A Go and Grafana Loki prototype is evaluated on an eight-node WSL/Docker cluster (180 s load, concurrency 50, three repeats per mode), complemented by 16-node and 32-node scale validations, distribution-preserving multi-process simulations, and algorithm microbenchmarks. Directed collection limits Loki ingested logs to 72 entries versus 4388 ± 1 under the same-architecture full-collection baseline (98.4% relative reduction, combining directed filtering and emission-rate differences; same-frequency multi-process simulation shows a 67.8% independent reduction from policy filtering). After clearing counters, the 16-node validation produces 6703.33 ± 91.78 gateway traffic logs per 60 s run while storing 48.0 ± 5.2 logs in Loki; the 32-node validation produces 6692.67 ± 121.88 gateway logs while storing 99.0 ± 0.0 logs. Average agent CPU and memory decrease by 37.5% and 2.0% respectively. The end-to-end pipeline—Nginx shared memory $\rightarrow$ Agent gRPC $\rightarrow$ Redis $\rightarrow$ attention-list generation—is verified in production-like experiments.

Key words: microservice; distributed directed log collection; attention list; dynamic policy; exponential backoff; Loki

Authors: Honglei Shi (Corresponding author), Juanjuan Zhao, Taiyuan University of Technology, Taiyuan 030024, China. E-mail: shihonglei0042@link.tyut.edu.cn

1 引言

微服务架构通过服务拆分提升了系统的可扩展性与开发敏捷性，容器编排、Sidecar与服务治理模式进一步推动了云原生应用的大规模部署^[2;3;10;21;33;36]。但这种架构也使日志产生源头高度分散：每个服务实例独立输出日志，格式因技术栈而异，总量随请求并发线性增长。传统可观测性方案多采用**全量采集**策略，在中小规模场景下尚可接受；当集群规模达到数十至数百节点时，全量采集将导致节点 CPU/内存持续占用、南北向带宽成为瓶颈、存储与索引成本急剧上升，且海量低价值日志淹没关键故障信息^[9;20;39;42]。

现有研究集中在日志存储压缩、采样过滤、故障诊断与 eBPF 无侵入采集等方向，但较少从**网关流量感知**出发，动态驱动各服务节点的应用日志定向采集。包航宇等^[35]总结智能运维实践与标准化框架，贾统等^[47]系统梳理基于日志的分布式软件系统故障诊断技术。本文将研究对象前移到**采集前端**：利用网关作为南北向流量入口所掌握的

URL、状态码、响应时延等结构化信号，在不侵入业务代码的前提下识别高价值请求，进而指导下游节点仅采集与异常、慢请求相关的应用日志，实现“只采必要日志”。

本文凝练的科学问题是：在不侵入业务代码、不改变微服务业务调用链的条件下，能否将网关层可观测到的流量异常信号转化为节点侧应用日志采集约束，使系统在保留异常、慢请求等高价值上下文的同时，显著降低日志入库量、节点资源开销与后端存储压力？围绕该问题，本文进一步拆解出四个可验证子问题：网关流量日志能否动态生成有效关注清单；关注清单能否跨网关、节点与中心三层保持语义一致；定向采集是否会引入不可接受的 Sidecar 资源开销；固定缓存块与压力感知退避能否支撑中心不可达或短时拥塞下的可靠传输。

本文的科学假设包括：(H1) 网关访问日志中的 URL、状态码与响应时延能够作为应用日志价值的先验信号，足以生成覆盖异常与慢请求模式的动态关注清单；(H2) 将该关注清单下发至节点侧 Sidecar 后，可在规则级保留关键请求上下文，并使 Loki 入库量相较同架构全量采集显著下降；(H3) 通过网关预筛选、节点定向采集与中心二次过滤之间的三次策略转换，可以维持跨层策略语义一致，形成端到端采集闭环；(H4) 固定缓存块与指数退避机制能够在低资源占用下提供有界重试与传输缓冲能力。后文实验部分以 RQ1-RQ4 对上述假设进行映射验证。

基于上述科学问题与假设，本文提出**分布式定向日志采集框架与原型组件**。框架由**网关预筛选、节点定向采集、中心二次过滤**三层组成，并通过三次策略转换保持跨层语义一致。相较 Promtail/Fluent Bit 全量推送后在存储端压缩的传统方案，本文在采集前端将 Loki 入库量控制在百条量级（八节点实测详见 §6.3），从源头降低网络与存储开销。主要贡献如下：

(1) 提出可复用的三层分布式定向采集框架，支持网关节点与微服务节点以 Sidecar 方式部署，中心负责策略生成与二次过滤，节点负责本地匹配、缓存与可靠上传，补足 AIOps 数据链路中的采集前端减量环节。

(2) 给出关注清单动态生成、固定缓存块、定向策略三次转换及压力感知指数退避的形式化描述与 Go 语言实现；关注清单生成复杂度：排序实现上界为 $O(N \log N)$ ，最小堆实现为 $O(N \log K)$ (K 为清单大小， $K \ll N$ ；见算法 1)。

(3) 构建基于 Docker Compose 的可复现原型与多进程模拟器，在八节点集群上完成 180s、 $n=3$ 重复对比实验、算法微基准与系统级组件消融，并补充清空统计后的十六/三十二节点规模复核；八节点结果显示 Loki 入库 72 条 vs. 全量 4388 ± 1 条（含定向过滤与发射频率差异的联合效果），多进程同频模拟证实策略过滤独立降幅为 67.8%，十六/三十二节点复核进一步验证了定向模式在扩展规模下的低入库量与低 Agent CPU 开销。

本文第 2 节综述相关工作；第 3 节介绍系统总体设计；第 4 节阐述关键算法；第 5 节描述实现细节；第 6 节给出实验与分析；第 7 节总结全文。

2 相关工作

2.1 集中式日志栈

ELK/EFK 以 Elasticsearch 为核心，检索能力强但索引成本高。国内外日志管理综述均指出，大规模软件系统日志在采集、传输、存储、解析和查询阶段都会引入显著成本^[9;39;42;49]。现有降低成本的方法主要包括日志压缩、日志模式挖掘、模板解析、云日志低成本存储和离线数据集构建^[12;14;30;50]。这些工作对入库后的压缩、解析和数据治理具有价值，但多数默认日志已经被采集到中心端；本文关注的是日志进入中心前的**采集前端定向减量**。

2.2 采样与追踪关联

OpenTelemetry 尾部采样依赖分布式追踪上下文，在请求完成后决定是否保留关联 span 或关联日志^[4]。工业调研和云原生可观测性综述显示，追踪、指标和日志三类遥测数据在微服务排障中通常需要联合分析^[15;16;20]。国内研究围绕分布式追踪、调用链存储、服务依赖发现和微服务故障检测展开^[32;38;40;43;46;51]。在根因定位方面，执行轨迹故障诊断、MicroRCA、多模态诊断和 RCA 综述分别从轨迹监测、拓扑依赖、多源信号和方法体系角度推进后端分析^[23;24;28;45]。与这些工作不同，本文不以已完整采集的 trace/log 数据为前提，而是用网关 access log 动态生成 URL 模式清单，在 Sidecar 层决定哪些应用日志需要上传。

2.3 边缘采集与可靠传输

边缘计算和云原生场景要求采集组件在低带宽、低资源和中心暂不可达时保持有界退化^[20;22;34]。Service Mesh 研究表明 Sidecar 会带来额外延迟和资源开销，因此采集逻辑必须控制 CPU、内存和网络消耗^[18;29]。本文在 Sidecar 中引入固定上限缓存块与压力感知退避，并辅以 BoltDB 本地兜底，使节点侧采集在资源受限情况下保持可控。

2.4 AIOps 实践与标准化

包航宇等^[35]基于大规模企业调研总结智能运维实践现状，并提出 AIOps-OSA 能力建设框架。云平台 AIOps 综述、MLOps/AIOps 系统综述与微服务生命周期智能化研究进一步说明，生产系统需要将运行时数据、自动化分析和工程治理形成闭环^[5;13;16]。本文聚焦其中**数据采集能力**的前端减量：通过网关流量驱动的关注清单，降低进入日志平台和后续算法模块的数据规模。

2.5 日志解析与故障诊断

贾统等^[47]将研究重点放在日志收集之后的解析、异常检测、故障定位和知识提取等环节。日志解析方面, Logram、模板识别与大规模日志解析评测推动了非结构化日志到结构化事件的转换^[6;11;12]。异常检测方面, CNN-text、LogFormer、机器学习综述、深度学习失效预测评估、融合学习时序异常检测与微服务性能异常检测展示了日志智能分析进展^[1;7;8;27;37;41;44]。多变量日志异常检测与图式根因分析进一步扩展了故障诊断能力^[19;26]。与这些工作相比, 本文关注**诊断前置条件**: 在日志尚未大规模入库前完成定向减量, 尽量保留错误、慢请求等高价值上下文。

2.6 微服务工程与云原生生态

微服务涉及服务拆分、持续软件工程治理与运行时配置管理^[10;17;31;48]。容器编排和微服务模式为 Sidecar 采集提供了部署基础^[2;3;21]。因此, 本文在实验节明确区分原型验证、基于真实分布的多进程模拟验证与生产级证据, 并将 Promtail 静态过滤作为同负载模拟基线, 将 OpenTelemetry 和 eBPF 作为后续端到端部署基线。

2.7 新兴采集技术与最接近先例

eBPF 技术使内核级日志与事件采集成为可能^[18;25]。然而, eBPF 方案侧重**基础设施级**事件, 对**应用级**日志的定向采集支持有限, 且缺乏网关流量驱动的动态策略源。OpenTelemetry 尾部采样以**分布式追踪 span**为单位, 与本文以**URL 模式**为粒度的应用日志定向过滤存在互补关系。

与本文最接近的工业实践包括: (1) Envoy 代理的 AccessLog 过滤器支持按路由或状态码配置日志输出策略, 但仅作用于代理自身的 access log, 不驱动下游微服务的应用日志采集; (2) Kong API 网关的 File-log/TCP-log 插件可按路由启用日志记录, 但属于静态配置, 不具备基于流量统计的动态 URL 模式生成能力; (3) OpenResty 生态的 lua-resty-logger-socket 等模块实现了 Lua 层的动态日志控制, 但动态策略局限于网关节点自身, 未形成跨节点的应用日志定向采集闭环。

上述先例的共同特征是: 日志过滤决策**局限于单一节点**(代理或网关), 且多为**静态或手工配置**规则。本文的增量创新在于: 以网关流量统计为输入、自动生成 Top-*K* URL 模式清单、经 gRPC 下发至多个微服务节点驱动应用日志定向采集、最后由中心二次过滤保障语义一致——形成“网关流量 → 多节点应用日志动态清单 → 中心二次过滤”的**贯通闭环**。本文方案以规则驱动的轻量匹配替代 ML 推理, 更适合边缘资源受限环境。

2.8 与代表性方案对比

表 1 从策略输入、减量位置、日志削减证据、动态策略来源和 Sidecar 开销等维度对比本文与代表性方案。

表 1: 与代表性日志采集/可观测性方案对比

方案	策略驱动源	减量位置	日志削减证据	动态策略来源	Sidecar 开销	本文关系
ELK/EFK 全量	静态配置	存储后端	通常无采集前减量	无	依部署而定	存储与索引成本高
Loki/Promtail	标签/级别	静态过滤	依规则配置	静态文件	低至中	工业参照
OTel 尾部采样 ^[4]	Trace 上下文	Span 保留	依采样策略	追踪上下文	采集器开销	URL 粒度互补
eBPF 日志 ^[18;25]	内核探针	内核/系统事件	依探针选择	内核事件	无应用 Sidecar	零侵入但无网关策略驱动
AIOps 标准化 ^[35]	运维能力框架	平台能力层	非采集算法	标准化能力模型	非组件级	本文支撑数据采集能力
日志故障诊断综述 ^[47]	已入库日志	分析阶段	非采集减量	后端诊断任务	非组件级	本文减少诊断输入规模
调用链异常定位 ^[32]	调用链	定位阶段	非采集减量	Trace/控制流	依追踪系统	侧重事后定位
本文	网关流量	采集前端	72 vs 4388 条 *	Top-K URL 清单	0.05% CPU*	前端定向减量框架

2.9 本文定位

综上，包航宇等 AIOps 标准化研究解决平台能力建设问题^[35]，贾统等日志诊断综述解决后端分析方法体系问题^[47]；二者均需要稳定、低成本且高价值的日志输入。本文定位为 **AIOps 采集前端的定向减量技术**：将网关 access log 作为动态策略输入，下发至各微服务节点做应用日志定向采集，再由中心二次过滤后入库。通过关注清单、三次策略转换与可复现 Docker 原型，本文在采集阶段将入库量控制在百条量级 *，并与全量 Sidecar 架构进行对照实测（详见 §6.3 表 5）。

* 八节点、180s、 $n=3$ ；全量基线发射频率（400ms）高于定向模式（2s），降幅为策略过滤与源配置联合效果；基于真实分布的多进程同频模拟表明，策略过滤独立降幅为 67.8% (§6.3)。

3 系统总体设计

3.1 架构概述

系统由日志节点采集器（Agent）与日志中心（Center）组成。Agent 分为网关节点实例与微服务节点实例：前者通过 OpenResty Lua 采集 HTTP 流量日志；后者采集应用访问日志。Center 负责接收 Agent 上传、生成关注清单、下发规则、执行二次过滤并写入 Loki。图 1 给出总体架构。

从能力边界看，本文框架可抽象为**网关预筛选、节点定向采集、中心二次过滤**三层，如表 2 所示。三层分别对应运行时流量感知、本地日志减量与中心入库控制，输入/输出均可独立审计，也便于与 AIOps 平台的数据采集能力对接。

3.2 工作流程

系统按以下步骤运行：

1. 网关在 log_by_lua 阶段采集 URL、状态码、响应时延等字段，写入共享内存缓冲区；
2. 网关 Agent 周期性拉取流量日志并 gRPC 上传至 Center，Center 缓存于 Redis；

表 2: 分布式定向日志采集框架的三层输入/输出

层级	输入	输出	作用
网关预筛选	HTTP access log、状态码、响应时延	高价值流量日志与 URL 模式候选	从入口流量识别错误、慢请求和热点异常模式
节点定向采集	关注清单、本地 Apache Combined 风格应用日志	命中关注清单的应用日志批次	在 Sidecar 内完成采集前端减量，降低上传量
中心二次过滤	节点上传批次、关注清单版本、去重状态	Loki 入库日志与可查询标签	统一策略语义，过滤过期或重复日志，保留高价值上下文

图1 分布式定向日志采集系统总体架构




图 1: 分布式定向日志采集系统总体架构

3. Center 对流量日志执行高价值过滤与 URL 聚类, 生成 Top- K 关注清单并 gRPC 下发;
4. 微服务 Agent 按清单匹配本地应用日志, 写入固定缓存块, 异步压缩上传;
5. Center 二次过滤、去重后批量推送至 Loki, 供 Grafana 查询。

3.3 部署模式

Sidecar 模式: Agent 与业务容器共享网络命名空间 (`network_mode: service:*`), 适用于 Kubernetes 或 Docker Compose。 **混合开发模式:** 基础设施容器化, Center/Agent 本地调试。原型部署于 WSL2, 网关映射端口 8088 (规避 Windows IIS 占用 80 端口)。

4 关键算法

4.1 关注清单动态生成

输入: 时间窗口内网关流量日志集合 $L = \{l_1, \dots, l_N\}$; 定向策略 S (响应时延阈值 T 、错误码集合 E)。

输出: 关注清单 $A = \{(p_i, w_i)\}$, p_i 为泛化 URL 模式, w_i 为权重。

Algorithm 1: 关注清单动态生成

Input: 流量日志集合 L , 策略 $S = (T, E, K, \text{TTL})$

Output: 关注清单 A

```

1  $H \leftarrow \emptyset$ ;
2 foreach  $l \in L$  do
3   if  $\text{rt}(l) > T$  or  $\text{status}(l) \in E$  then
4      $p \leftarrow \text{Generalize}(l.\text{url})$ ;           // 数字  $\rightarrow \{\text{id}\}$ , UUID  $\rightarrow \{\text{uuid}\}$ 
5      $H[p].\text{count} \leftarrow H[p].\text{count} + 1$ ;
6      $H[p].\text{severity} \leftarrow \max(H[p].\text{severity}, \text{Sev}(l))$ ;
7 foreach  $p \in H$  do
8    $w_p \leftarrow \alpha \cdot H[p].\text{count} + \beta \cdot H[p].\text{severity}$ ;
9  $A \leftarrow \text{TopK}(H, K)$ ;                      // 按  $w_p$  降序取前  $K$  项
10 foreach  $(p_i, w_i) \in A$  do
11   附加 TTL;
12 return  $A$ ;
```

算法首先线性扫描 N 条流量日志, 并将满足阈值条件的记录映射到 M 个泛化 URL 模式 ($M \leq N$)。Top- K 选取有两种实现: (1) 全量排序, 复杂度 $O(N + M \log M)$, 上界

可简写为 $O(N \log N)$; (2) 大小为 K 的最小堆, 复杂度 $O(N + M \log K)$, 当 $K \ll M$ 时更优。当前原型采用排序实现, 便于审计和复现实验。URL 泛化规则包括: 纯数字路径段映射为 $\{id\}$, UUID/长哈希段映射为 $\{uuid\}$, 查询参数按键名归一化; 因此 Apache Combined 风格访问日志可直接转换为关注清单项。对于加密日志、非 URL 型业务日志或异常极稀疏窗口, 算法退化为仅保留 ERROR 级别兜底规则。微基准在 5000 条合成日志上耗时约 15 ms (图 6)。相较 Promtail 依赖静态标签配置, 本算法以网关 access log 为策略输入, 动态识别高价值 URL 模式。

4.2 固定缓存块

每节点预分配固定大小内存块 B (默认 64–128 MB), 内部为环形队列, 双重约束条目数与字节数。占用率超过阈值 θ (默认 80%) 或定时器触发时异步 gzip 上传; 队列满则 FIFO 淘汰, 保障内存有界。

4.3 定向策略三次转换

为实现策略在不同层级的语义一致, 提出三次转换 (图 2):

阶段	输入	输出	作用
第一次	定向策略 S	网关采集规则	Nginx 预筛选 (阈值 $T/5$)
第二次	网关日志 + S	Agent 过滤规则	驱动节点定向采集
第三次	关注清单 + 服务日志	Loki 存储规则	中心二次过滤与入库

三次转换的正确性依赖同一关注清单版本号 v 和同一 URL 泛化函数 $\text{Generalize}(\cdot)$ 。第一次转换保证进入候选集合的流量日志满足宽松阈值, 避免在网关侧过早丢弃潜在异常; 第二次转换将候选集合压缩为 Top- K URL 模式, 使 Agent 本地匹配谓词与中心策略一致; 第三次转换在入库前校验清单版本、TTL 与去重键, 过滤过期或重复日志。因此, 只要服务日志中的 URL 字段可由同一泛化函数解析, 且清单 TTL 未过期, 节点侧命中的日志不会在中心侧因策略语义漂移被错误丢弃。若字段缺失或格式不兼容, 系统按 ERROR 级别兜底规则处理, 并在 Center 记录未匹配原因。

4.4 压力感知指数退避

上传失败时, 第 n 次重试延迟定义为

$$d_n = \min(d_{\max}, d_0 \rho^n + \text{rand}(0, d_0 \rho^n \xi)). \quad (1)$$

其中, n 表示当前重试序号, d_n 表示第 n 次重试前的等待时间, $d_0=200$ ms 为初始延迟, $\rho=2.0$ 为指数增长因子, $d_{\max}=30$ s 为单次等待上界, $\xi=0.3$ 为随机抖动系数, $\text{rand}(\cdot)$ 表示均匀随机扰动。当前实现最大重试 6 次; 节点资源高压时 d_n 翻倍; 不可重试错误写入 BoltDB 本地兜底。分布见图 3。

图2 定向策略三次转换算法流程




图 2: 定向策略三次转换算法流程

由于 d_n 被 $d_{\max}$ 截断且最大重试次数固定为 6，单批日志的在线重试等待时间有上界：正常压力下不超过 $6d_{\max}$ ，高压翻倍时不超过 $12d_{\max}$ 。超过重试上限后批次进入本地 BoltDB 兜底队列，后续由后台恢复任务按清单版本重新上传，从而避免无限重试占满 Sidecar 资源。

图5 指数退避重试延迟分布




图 3: 指数退避重试延迟分布

表 3: 技术选型

模块	技术
Agent / Center	Go 1.22
通信	gRPC + Protobuf
缓存	Redis
存储	Grafana Loki
网关采集	OpenResty + Lua
本地兜底	BoltDB

5 系统实现

5.1 技术选型

5.2 模块划分

系统实现分为 Agent 与 Center 两大模块。**Agent** 负责节点侧的日志采集 (collector)、规则匹配 (matcher)、固定缓存块管理 (cache)、退避重试 (retry)、gRPC 上传 (uploader) 和资源监控 (monitor)，代码位于 `agent/pkg/` 各子包。**Center** 负责关注清单生成与三次转换 (strategy)、二次过滤 (receiver)、Loki 批量推送 (storage) 和规则下发 (dispatch)，代码位于 `center/pkg/` 各子包。

5.3 关键数据结构与匹配实现

关注清单在 Redis 中按版本存储：Center 生成新清单后先写入版本化键，再原子更新当前版本指针；Agent 拉取时携带本地版本号，仅在版本变化或 TTL 即将过期时更新规则，减少不必要的网络往返。节点侧匹配器将 URL 模式编译为前缀/通配匹配规则，并按服务名分桶，单条日志匹配复杂度近似为 $O(R_s)$ ，其中 R_s 为该服务当前关注规则数；在 Top- K 限制下， R_s 通常远小于全局规则数。应用日志采用 Apache Combined 风格字段，至少包含时间戳、方法、URL、状态码与响应字节数；非兼容格式需要通过解析适配器转换为统一字段后再进入匹配器。

5.4 部署配置

Docker Compose 定义完整集群：Loki、Grafana、Redis、Prometheus、Center、OpenResty 网关、httpbin 模拟微服务及 9 个 Agent Sidecar (1 网关 + 8 微服务)。微服务侧 AppCollector 生成 Apache Combined 风格应用日志，URL 与网关 location 前缀一致。无关注清单时 Agent 仅采集 ERROR 及以上级别，避免退化为全量。WSL 环境通过 `docker-compose.wsl.yml` 限制容器内存；`docker-compose.scale.yml` 扩展至 8 微

服务节点。

对照实验配置说明：定向模式下应用日志发射间隔为 2s；全量基线模式为 400ms（更高吞吐），以模拟“尽可能多采”的工业全量场景。对比时两模式共享同一网关压测负载与硬件环境。

5.5 生产部署与标准化接口

在 Kubernetes 环境中，网关 Agent 可部署为 Sidecar 或 DaemonSet，微服务 Agent 优先以 Sidecar 方式与业务容器共享网络命名空间；对日志文件路径统一的集群，也可采用 DaemonSet 降低实例数。生产部署需启用 gRPC TLS、Agent 身份认证和租户隔离，关注清单键空间按租户、命名空间和服务名分层，避免跨租户规则泄露。标准化方面，关注清单可公开为包含 `version`、`ttl`、`service`、`pattern`、`weight` 与 `reason` 字段的 JSON 规范，并与 OpenTelemetry Collector 的过滤处理器、Loki 标签模型对接。按 AIOps-OSA 的能力划分，本文组件承担数据采集层的动态减量和场景实现层的异常/慢请求上下文保留，为后续日志解析、异常检测和根因定位提供更小但更高价值的输入。

6 实验与分析

6.1 环境与方法

实验在 WSL2/Docker 原型集群上进行。主对比实验使用 8 节点配置，规模复核实验扩展至 16/32 个 httpbin 微服务及对应 Sidecar Agent；集群另含 1 个 OpenResty 网关、1 个日志中心及 Loki/Redis 等基础设施。应用日志采用 Apache Combined 风格字段，URL 与网关路由一致。

对比实验将定向采集与全量采集（`COLLECTION_MODE=full`）在同一硬件环境下对照：负载为 180s、并发 50 的混合 HTTP 请求（含正常/500 错误/慢请求），每模式独立重复 3 次。Loki 入库增量取自 Center 统计接口；Agent CPU/内存于每轮压测结束后对全部 9 个 Agent 容器执行 `docker stats` 单次快照并取算术均值。每轮网关流量日志 Redis 增量约 1.97×10^4 条，关注清单稳定生成 16 条 URL 模式（含 `/status/500`、`/delay/1` 等异常/慢请求泛化模式），保障高价值请求可被定向规则覆盖。原始数据见 phase3 结果 JSON；清空统计后的 16/32 节点规模复核见 phase4 结果 JSON；同频率对照、Promtail 静态过滤复现与系统级组件消融见 phase5 多进程模拟结果 JSON。

6.2 研究问题与指标

为使实验与贡献形成可审计对应关系，本文围绕 4 个研究问题组织实验，如表 4 所示。RQ1 对应采集前端减量能力，RQ2 对应 Sidecar 资源开销，RQ3 对应三层策略贯通能力，RQ4 对应缓存与退避机制的可靠性边界。

表 4: 研究问题、指标与证据映射

编号	研究问题	指标	证据位置
RQ1	定向采集能否显著降低 Loki 入库日志量?	Loki 入库条数、带宽估计、降低比例	表 5、图 4
RQ2	定向采集是否控制 Sidecar 资源开销?	Agent CPU、内存均值与标准差	表 5、图 4
RQ3	网关预筛选、节点定向采集与中心二次过滤是否形成端到端闭环?	Redis 网关日志增量、关注清单模式数、链路阶段打通情况	§6.3 与原始 phase3 JSON
RQ4	固定缓存块与压力感知退避是否具有必要性与有界性?	策略仿真消融、微基准耗时、退避单元测试与等待上界	图 5、图 6、式 1

6.3 实验结果

表 5 与图 4 给出 RQ1 与 RQ2 的三期实测对比。相较同架构全量模式，定向采集在 Loki 入库日志量上降低 98.4% (72 ± 0 条 vs. 4388 ± 1 条)，在 Agent CPU 上相对降低 37.5% (绝对值分别为 $0.05 \pm 0.01\%$ 与 $0.08 \pm 0.02\%$ ，标准差存在重叠，宜结合效应量解读)。需指出：全量基线除关闭规则过滤外，应用日志源发射频率 (400 ms) 亦高于定向模式 (2s)，表 5 降幅为**策略过滤与源配置差异的联合效果**。

效应量分析。对 Loki 入库量 (72 ± 0 vs. 4388 ± 1)，Cohen's $d \approx 6100$ ，效应量极大，即使 $n=3$ 检验功效也充分可靠。对 Agent CPU ($0.05 \pm 0.01\%$ vs. $0.08 \pm 0.02\%$)，绝对差值仅 0.03 个百分点，Cohen's $d \approx 1.9$ ，在 $n=3$ 下检验功效有限；Agent 内存相对差异 2.0% 在统计上不显著。因此，本文以 Loki 入库量降幅为主要结论，Agent CPU/内存降幅作为辅助参考。

发射频率敏感性分析。全量基线发射频率 (400 ms) 高于定向模式 (2s)，本文通过构建**多进程集群模拟器**补充了同频率对照实验以隔离策略过滤贡献。该模拟器以 phase3 实测负载分布、URL 结构与节点数为输入，并采用虚拟时间推进，避免在 WSL/Docker 资源约束下重新拉起高频长稳集群。模拟控制两者发射频率完全一致 (2s)：定向模式模拟入库 231.7 条，而全量模式 (2s) 入库 720 条。完全剔除源发射频率差异后，策略过滤带来的独立相对降幅为 **67.8%**，占原稿实测降幅 (98.4%) 的主要贡献。这验证了动态定向清单即使在严格同源配置下仍具备显著减量价值。

图 5 为 RQ4 的策略仿真消融。为补充系统级组件消融证据，本文进一步开展多进程模拟消融：关闭关注清单导致 Loki 入库量激增 211.7% (退化为全量)，验证了清单匹配是减量的绝对核心；关闭二次过滤与固定缓存块对入库总量无显著影响 (波动不超过 1%)，仅影响传输批次大小，验证了其作为传输层稳定性保障组件的作用。

针对 RQ3，端到端链路已实测打通：Nginx 共享内存 $\rightarrow$ Agent gRPC $\rightarrow$ Redis $\rightarrow$ 关注清单生成 $\rightarrow$ Agent 规则拉取 (复现脚本见 `experiments/scripts/phase3_collect`。

表 5: 定向采集与全量采集资源对比 (八节点, 180 s, $n=3$ 实测)

指标	定向采集	全量采集	降低比例
Loki 入库 (条)	72 $\pm$ 0	4388 $\pm$ 1	98.4%
Agent CPU (%)	0.05 $\pm$ 0.01	0.08 $\pm$ 0.02	37.5%
Agent 内存 (MB)	95.6 $\pm$ 4.2	97.5 $\pm$ 1.7	2.0%
带宽 (KB/s)	0.20	12.19	98.4%

图3 定向采集与全量采集资源消耗对比 (首期仿真)


图 4: 定向采集与全量采集资源消耗对比 (八节点, 180 s, $n=3$ 实测)

图4 消融实验结果 (首期仿真)




图 5: 消融实验结果 (策略仿真, 非集群实测)

py, 原始结果见 experiments/results/phase3/phase3_latest.json)。针对 RQ4, 关注清单生成在 5000 条日志上耗时约 15ms (图 6); 指数退避模块通过 agent/pkg/retry/backoff_test.go 全部单元测试用例; 多进程模拟脚本与结果见 experiments/scripts/phase5_multiprocess_sim.py 和 experiments/results/phase5/phase5_latest.json。




图 6: 关注清单生成算法微基准

6.4 可复现性与效度威胁

实验脚本、Docker Compose 配置与原始 JSON 结果保存在 experiments/ 及 phase3/phase4/phase5/ 结果目录, 图 4、表 5 均由 phase3 JSON 派生; 清空统计后的 16/32 节点规模复核分别由 experiments/results/phase4/phase4_20260611_021230.json 与 experiments/results/phase4/phase4_20260611_024321.json 派生; 同频率对照、Promtail 静态过滤复现与系统级组件消融由 phase5 JSON 派生。当前结果仍存在以下效度威胁。

规模效度: 八节点主对比和十六/三十二节点规模复核为 WSL/Docker 实测, 六十四节点仍为基于实测曲线的外推; 云环境长稳与带宽压力仍需验证。

基线效度: 已给出同架构全量实测基线、Promtail 静态过滤的同负载模拟复现, 以及 OpenTelemetry/eBPF 同负载估算 (图 8)。Promtail、OpenTelemetry 与 eBPF 的完整端到端部署对照仍待补充。

负载效度: 当前负载由 httpbin 合成, 覆盖正常、错误与慢请求, 但距离 DeathStar-Bench、Alibaba 生产迹等真实微服务流量仍有差距。

统计效度: 三期对比为 180s、 $n=3$; 四期规模矩阵为 60s、 $n=3$; 五期多进程模拟同

样重复 3 次，但仍属于基于实测分布的模拟证据。逐探针命中率受 Agent 批处理影响，不能单独代表稳态漏报率。图 5 为策略仿真消融，不能与表 5 的集群实测直接比较。

6.5 规模扩展与质量指标

在四期实验中，本文补充了 16/32 节点定向模式规模复核（60s、并发 50、重复 3 次）。为避免历史计数影响，复核前执行 Redis 清空与 Center 重启，使 `/api/v1/stats` 从 0 开始计数。图 7 显示：在 16 节点下，网关流量日志增量为 6703.33 ± 91.78 条/轮，定向模式 Loki 入库为 48.0 ± 5.2 条/轮，关注清单稳定为 32 项；在 32 节点下，网关流量日志增量为 6692.67 ± 121.88 条/轮，定向模式 Loki 入库稳定为 99.0 ± 0.0 条/轮，关注清单达到当前 $\text{Top-}K=50$ 上限。32 节点 Agent 平均 CPU 为 $0.06 \pm 0.01\%$ ，Center CPU 为 $0.06 \pm 0.07\%$ ，未出现资源失控。64 节点柱形为基于现有实测趋势的外推值（灰色），**仅供趋势参考，不作为本文主要结论**。外推假设资源消耗与节点数呈近似线性关系，实际分布式系统可能因网络竞争、调度抖动等因素产生非线性增长，需在云环境长稳压测中验证。




图 7: 多规模扩展实验（绿色/实线：8/16/32 节点集群实测；灰色/虚线：64 节点线性外推，非实测）

漏报定义与度量。本文区分两类指标：（1）**规则级漏报**——关注清单是否覆盖了所有满足定向策略条件（响应时延 $> T$ 或状态码 $\in E$ ）的 URL 模式；（2）**探针即时命中率**——某一时刻向指定服务发送探针请求后，对应应用日志是否被 Agent 批处理窗口内立即采集并上传。稳态混合负载下，关注清单稳定覆盖 `/status/500`、`/delay/1` 等泛化模式（八节点 16 条、十六节点 32 条），**规则级漏报率为 0**。需指出：该结论在合成负载与当前清单配置（ $\text{Top-}K=50$ 、固定 URL 集合）下成立；生产环境 URL 模式长尾分布、窗口大小与 $\text{Top-}K$ 参数均可能影响覆盖率。生产迹风格混合负载（60% 正常 / 20% 5xx / 12% 慢请求 / 8% 其他，90s、十六节点）共发送 3.6×10^4 次请求，定向入库 77 条，验证减量能力。逐探针实验的即时命中率受 Agent 2s 批处理窗口影响，反映的是**批处理延迟对采集时效性的影响**，不等同于规则级漏报。

端到端延迟与可接受性。端到端延迟（HTTP $\rightarrow$ Center received）实测：P50 0.83s、P95 12s ($n=30$)。P95 较高主要源于 Agent 2s 批处理窗口与合成慢请求（如 `/delay/1`

引入 1s 额外响应时间) 的叠加。就可接受性而言：在日志采集场景下，业界主流方案（如 ELK/Promtail 推送链路）的典型端到端延迟为 30s-60s 量级，本文 P95=12s 处于合理范围；若需满足秒级实时告警 SLA，可通过缩小批处理窗口或引入事件驱动推送机制降低延迟（以增加上传频率为代价）。全量模式同样存在批处理与传输延迟，定向模式并未引入显著额外延迟。中心故障恢复实验（docker stop/start）恢复时间约 1.1s。

6.6 工业基线对照

图 8 在同负载口径下给出本文定向采集与三类工业基线的趋势对照。为补充实证对比，本文在多进程模拟器中复现了 Promtail 静态标签过滤（保留 status $\geq$ 400 错误或 /delay/ 慢请求路由）。模拟结果显示，同负载分布下 Promtail 静态过滤入库 276.3 条，而本文定向策略入库 233.3 条；因引入网关流量驱动的动态 Top- K 机制（截断长尾异常），定向采集较静态阈值规则拦截了更多噪音。需强调的是，该结果是**规则级模拟复现**，不是 Promtail 完整部署下的端到端吞吐、资源与延迟对照。OpenTelemetry 尾部采样估算^[4]与 eBPF 内核探针估算^[18]暂未进行实测，图中柱形应解读为**趋势参考**。本文**不主张**在所有维度上优于工业方案，核心创新在于补齐以应用日志内容特征为基础的采集前端轻量级减量闭环。




图 8: 工业基线趋势对比 (P3 定向采集为集群实测; Promtail 为同负载多进程规则复现; OTel/eBPF 为同负载估算, 柱形样式区分证据等级)

6.7 剩余局限与后续工作

四期实验已补充 8/16/32 节点规模矩阵、规则级漏报验证、端到端延迟与工业基线估算；五期多进程模拟进一步补齐了原稿在同频率发射对照、Promtail 静态过滤对照及系统级组件消融方面的缺失环节，使得基于模拟评估的理论界限有迹可循。未来的主要工作方向如下：

近期/中期工作：（1）64 节点云环境（Kubernetes）实测，替代当前基于 32 节点复核结果的趋势外推，并评估 Top- K 参数对长尾 URL 覆盖率的影响；（2）引入 DeathStarBench、Alibaba 生产迹等真实微服务负载，进一步验证 URL 模式长尾分布下的动态关注清单覆盖率与召回性能；（3）构建完整的商业成本量化模型，将相对日志减量直接转化为存储及网络带宽的绝对费用节约估算。

远期工作：（4）与 OpenTelemetry 追踪上下文、eBPF 应用日志挂钩集成，探索采集前减量与后端智能诊断（如根因定位）的无缝闭环；（5）推进系统关键组件的生产级能力，涵盖 gRPC TLS 安全通信、多租户策略隔离、可配置的隐私脱敏以及规范化的清单 JSON 开源标准设计。

7 结束语

本文面向微服务可观测性场景，提出分布式定向日志采集框架与原型组件，主要贡献体现在以下三个方面：

（1）**网关驱动的动态 Top- K 关注清单生成。**以网关流量日志作为策略源，通过高价值过滤、URL 聚类泛化与 Top- K 筛选（算法 1），动态识别异常与慢请求 URL 模式，生成关注清单经 Redis 下发至各节点。该策略源创新使得定向采集决策由流量驱动而非静态配置。

（2）**跨三层的定向策略转换算法。**通过三次转换贯通网关预筛选、节点定向采集与中心二次过滤，实现策略在不同层级的语义一致（图 2），避免了单层采集器配置的局限性。

（3）**资源受限下的固定缓存与压力感知退避机制。**在 Sidecar 中引入固定上限缓存块与压力感知指数退避，辅以 BoltDB 本地兜底，保障内存有界传输，适应边缘资源受限环境。

基于 Go、gRPC、Redis 与 Loki 的原型在 WSL/Docker 八节点集群上完成端到端验证，并通过 16/32 节点规模复核与基于真实分布的多进程模拟器补充了同频率对照、Promtail 静态过滤复现与组件消融。相较同架构全量采集，定向模式将 Loki 入库量控制在百条量级（八节点实测 72 条 vs. 全量 4388 ± 1 条，详见表 5）；该降幅为策略过滤与源发射频率差异的联合效果，其中策略过滤在同频率模拟下独立降幅为 67.8% (§6.3)。清空统计后的规模复核显示，16 节点网关流量日志增量为 6703.33 ± 91.78 条/轮、定向模式 Loki 入库为 48.0 ± 5.2 条/轮，32 节点网关流量日志增量为 6692.67 ± 121.88 条/轮、定向模式 Loki 入库为 99.0 ± 0.0 条/轮；32 节点下关注清单达到 Top- $K=50$ 上限。Promtail 静态过滤复现中，本文定向策略入库 233.3 条，低于静态规则的 276.3 条；组件消融中，关闭关注清单使入库量增加 211.7%，进一步说明动态清单是采集前端减量的关键环节。Agent CPU 绝对值均低于 0.1%。从 AIOps 生态看，本文工作补充了标准化框架中的数据采集前端能力；从日志故障诊断链路看，本文降低了后端解析、异常检测与根因定位的输入规模。

未来工作按优先级组织：近期将在 Kubernetes 环境开展 64 节点云原生实测，并补充 Top- K 参数敏感性分析；中期将引入 DeathStarBench、Alibaba 生产迹等真实微服务负载验证长尾分布覆盖率，并构建成本量化模型将入库降幅转化为实际成本节约；远期将探索与 OpenTelemetry 追踪上下文、eBPF 应用日志挂钩的集成，以及生产级 gRPC TLS、多租户策略隔离与关注清单 JSON 规范的开源与标准化对接。

声明

本文撰写与实验脚本生成过程中使用了大语言模型辅助，作者对全部内容与数据负责。

参考文献

- [1] Shan Ali, Chaima Boufaied, Domenico Bianculli, Paula Branco, and Lionel Briand. A comprehensive study of machine learning techniques for log-based anomaly detection. *Empirical Software Engineering*, 2025.
- [2] Brendan Burns, Brian Grant, David Oppenheimer, Eric Brewer, and John Wilkes. Borg, omega, and kubernetes. *Communications of the ACM*, 59(5):50–57, 2016.
- [3] Brendan Burns, David Oppenheimer, and Eric Brewer. Design patterns for container-based distributed systems. In *Proceedings of the 7th Workshop on Hot Topics in Cloud Computing (HotCloud)*. ACM, 2016.
- [4] Zhuangbin Chen, Zhihan Jiang, Yuxin Su, Michael R. Lyu, and Zibin Zheng. Tracemesh: Scalable and streaming sampling for distributed traces. *arXiv preprint arXiv:2406.06975*, 2024.
- [5] Qian Cheng, Doyen Sahoo, Amrita Saha, Wenzhuo Yang, Chenghao Liu, and Steven C. H. Hoi. Ai for it operations (aiops) on cloud platforms: Reviews, opportunities and challenges. *arXiv preprint arXiv:2304.04661*, 2023.
- [6] Hetong Dai, Heng Li, Weiyi Shang, Tse-Hsun Chen, and Che-Shao Chen. Logram: Efficient log parsing using n-gram dictionaries. *arXiv preprint arXiv:2001.03038*, 2020.
- [7] Hongcheng Guo, Jian Yang, Jiaheng Liu, Jiaqi Bai, Boyang Wang, et al. Logformer: A pre-train and tuning pipeline for log anomaly detection. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 135–143, 2024.

- [8] Fatemeh Hadadi, Joshua H. Dawes, Donghwan Shin, Domenico Bianculli, and Lionel Briand. Systematic evaluation of deep learning models for log-based failure prediction. *Empirical Software Engineering*, 2024.
- [9] Shilin He, Pinjia He, Zhuangbin Chen, Tianyi Yang, Yuxin Su, and Michael R. Lyu. A survey on automated log analysis for reliability engineering. *arXiv preprint arXiv:2009.07237*, 2020.
- [10] Pooyan Jamshidi, Claus Pahl, Nabor C. Mendonça, James W. Lewis, and Stefan Tilkov. Microservices: The journey so far and challenges ahead. *IEEE Software*, 35(3):6–9, 2018.
- [11] Zhihan Jiang, Jinyang Liu, Junjie Huang, Yichen Li, Yintong Huo, et al. A large-scale evaluation for log parsing techniques: How far are we? *arXiv preprint arXiv:2308.10828*, 2023.
- [12] Zhihan Jiang, Jinyang Liu, Junjie Huang, Yichen Li, and Michael R. Lyu. Lilac: Log parsing using llms with adaptive parsing cache. *arXiv preprint arXiv:2310.01796*, 2023.
- [13] Rodrigo Laigner, Yixin Zhou, Alan Salomao, Pengfei Zhou, Leonardo Carvalho, Alexander Romanovsky, and Claus Pahl. An empirical study on challenges of event management in microservice architectures. *arXiv preprint arXiv:2408.00440*, 2024.
- [14] Jinyang Liu, Jieming Zhu, Shilin He, Pinjia He, Zibin Zheng, and Michael R. Lyu. Logzip: Extracting hidden structures via iterative clustering for log compression. In *Proceedings of the 34th IEEE/ACM International Conference on Automated Software Engineering*, pages 863–875, 2019.
- [15] Abdullah Al Maruf, Alexander Bakhtin, Tomas Cerny, and Davide Taibi. Using microservice telemetry data for system dynamic analysis. *arXiv preprint arXiv:2207.02776*, 2022.
- [16] Sergio Moreschini, Davide Taibi, Valentina Lenarduzzi, and Claus Pahl. Ai techniques in the microservices life-cycle: A systematic mapping study. *arXiv preprint arXiv:2305.16092*, 2023.
- [17] Vishwanath Seshagiri, Darby Huye, Lan Liu, Avani Wildani, and Raja R. Sambasivan. [sok] identifying mismatches between microservice testbeds and industrial perceptions of microservices. *Systems Research*, 1(1), 2022.

- [18] David Soldani, Petrit Nahi, Hami Bour, Saber Jafarizadeh, Mohammed F. Soliman, et al. ebpf: A new approach to cloud-native observability, networking and security for current and future mobile networks. *IEEE Access*, 11:57174–57202, 2023.
- [19] Jacopo Soldani and Antonio Brogi. Graph-based root cause analysis for service-oriented and microservice architectures. *Journal of Systems and Software*, 159:110432, 2020.
- [20] Muhammad Usman, Simone Ferlin, Anna Brunstrom, and Javid Taheri. A survey on observability of distributed edge and container-based microservices. *IEEE Access*, 10:86904–86919, 2022.
- [21] Guilherme Vale, Filipe Figueiredo Correia, Eduardo Martins Guerra, Thatiane de Oliveira Rosa, Jonas Fritzsche, and Justus Bogner. Designing microservice systems using patterns: An empirical study on quality trade-offs. *arXiv preprint arXiv:2201.03598*, 2022.
- [22] Benjamin Varghese, Nikolaos Antonopoulos, and Rajkumar Buyya. A survey on edge performance benchmarking. *ACM Computing Surveys*, 55(3):1–35, 2022.
- [23] Tingting Wang and Guilin Qi. A comprehensive survey on root cause analysis in (micro) services: Methodologies, challenges, and trends. *arXiv preprint arXiv:2408.00803*, 2024.
- [24] Li Wu, Johan Tordsson, Erik Elmroth, and Odej Kao. Microrca: Root cause localization of performance issues in microservices. In *NOMS 2020 - 2020 IEEE/IFIP Network Operations and Management Symposium*, pages 1–9, 2020.
- [25] Wanqi Yang, Pengfei Chen, Kai Liu, and Huxing Zhang. Nahida: In-band distributed tracing with ebpf. *arXiv preprint arXiv:2311.09032*, 2023.
- [26] Lingzhe Zhang, Tong Jia, Mengxi Jia, Ying Li, Yong Yang, and Zhonghai Wu. Multivariate log-based anomaly detection for distributed database. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2024.
- [27] Lingzhe Zhang, Tong Jia, Kangjin Wang, Mengxi Jia, Yong Yang, and Ying Li. Reducing events to augment log-based anomaly detection models: An empirical study. In *Proceedings of the 39th IEEE/ACM International Conference on Automated Software Engineering*, 2024.
- [28] Shenglin Zhang, Pengxiang Jin, Zihan Lin, Yongqian Sun, et al. Robust failure diagnosis of microservice system through multimodal data. *arXiv preprint arXiv:2302.10512*, 2023.

- [29] Yuxin Zhang, Bowen Li, Xin Peng, Qilin Xiang, and Xuanzhe Liu. Technical report: Performance comparison of service mesh frameworks: the case of istio and linkerd. In *arXiv preprint arXiv:2411.02267*, 2024.
- [30] Jieming Zhu, Shilin He, Pinjia He, Jinyang Liu, and Michael R. Lyu. Loghub: A large collection of system log datasets for ai-driven log analytics. *arXiv preprint arXiv:2008.06448*, 2020.
- [31] 丁丹, 彭鑫, 郭晓峰, 张健, and 吴毅坚. 场景驱动且自底向上的单体系统微服务拆分方法. *软件学报*, 31(11):3461–3480, 2020.
- [32] 于庆洋, 白晓颖, 李明杰, 李奇原, 刘涛, 刘泽胤, and 裴丹. 基于调用链控制流分析的大型微服务系统性能建模与异常定位. *软件学报*, 33(5):1849–1864, 2022.
- [33] 冯志勇, 徐砚伟, 薛霄, and 陈世展. 微服务技术发展的现状与展望. *计算机研究与发展*, 57(5):1103–1122, 2020.
- [34] 刘敏 and 周傲英. 面向微服务架构的容器级弹性资源供给方法. *计算机研究与发展*, 54(5):957–967, 2017.
- [35] 包航宇, 殷康[☒], 曹立, 李世宁, et al. 智能运维的实践: 现状与标准化. *软件学报*, 34(9):4069–4095, 2023.
- [36] 吴化尧 and 邓文俊. 面向微服务软件开发方法研究进展. *计算机研究与发展*, 57(3):525–541, 2020.
- [37] 周小晖, 王意洁, 徐鸿祚, and 刘铭宇. 基于融合学习的无监督多维时间序列异常检测. *计算机研究与发展*, 60(3):496–508, 2023.
- [38] 尤勇, 汪浩, 任天, 顾胜晖, and 孙佳林. 一种监控系统的链路跟踪型日志数据的存储设计. *软件学报*, 32(5):1302–1321, 2021.
- [39] 廖湘科, 李姗姗, 董威, 贾周阳, 刘晓东, and 周书林. 大规模软件系统日志研究综述. *软件学报*, 27(8):1934–1947, 2016.
- [40] 张齐勋, 吴一凡, 杨勇, 贾统, 李影, and 吴中海. 微服务系统服务依赖发现技术综述. *软件学报*, 35(1):118–135, 2024.
- [41] 方浩天, 李春花, 王清, and 周可. 一种基于深度学习的微服务性能异常检测方法. *计算机研究与发展*, 61(3):600–613, 2024.
- [42] 李明树, 张艳, 王涛, and 刘俊. 大规模分布式系统日志管理技术综述. *软件学报*, 30(7):1959–1979, 2019.

- [43] 杨勇, 李影, and 吴中海. 分布式追踪技术综述. 软件学报, 31(7):2019–2039, 2020.
- [44] 梅御东, 陈旭, 孙毓忠, et al. 一种基于日志信息和 CNN-text 的软件系统异常检测方法. 计算机学报, 43(2):524–544, 2020.
- [45] 王智宇, 王涛, 张文博, 陈宁江, and 左春. 一种基于执行轨迹监测的微服务故障诊断方法. 软件学报, 28(6):1435–1454, 2017.
- [46] 王璐, 姜宇轩, 李青山, 霍其恩, 王展, 谢生龙, and 歹杰. 微服务故障检测研究综述. 计算机学报, 46(11):2342–2373, 2023.
- [47] 贾统, 李影, and 吴中海. 基于日志数据的分布式软件系统故障诊断综述. 软件学报, 31(7):1997–2018, 2020.
- [48] 贾统, 李影, 张齐勋, and 吴中海. 基于程序层次树的日志打印位置决策方法. 软件学报, 32(9):2713–2728, 2021.
- [49] 陈彦宁, 张广艳, and 陈康. 面向云数据中心多语法日志通用异常检测机制. 计算机研究与发展, 57(9):1844–1856, 2020.
- [50] 魏钧宇, 张广艳, and 陈军超. 数据模式感知的低成本云日志存储系统. 计算机研究与发展, 60(11):2442–2452, 2023.
- [51] 黄梓程, 陈鹏飞, 余广坝, and 陈泓仰. 面向 java 微服务系统的透明请求追踪及采样方法. 软件学报, 34(7):3167–3187, 2023.

作者简介

石洪雷, 男, 博士, CCF 专业会员, 太原理工大学, 主要研究领域为微服务可观测性、分布式日志采集与智能运维。E-mail: shihonglei0042@link.tyut.edu.cn。

赵涓涓, 女, 博士, CCF 杰出会员, 太原理工大学教授、博士生导师, 长期从事智能信息处理、模式识别、情感计算、图像处理等方面的科研工作。E-mail: zh_juanjuan@126.com。